Predição de Diabetes Utilizando Algoritmos de Machine Learning

Ciro Campos de Carvalho[1], Luiz Henrique Fabiano[2]

[1]Faculdade Presbiteriana Mackenzie

[2]Faculdade de Computação e Informática

10418360@mackenzista.com.br, 10418748@mackenzista.com.br

Abstract. *This project aims to develop a Machine Learning model to predict the likelihood of diabetes based on clinical patient data. The study uses a publicly available dataset containing variables such as glucose level, body mass index (BMI), age, and blood pressure. Classification algorithms, including K-Nearest Neighbors and Logistic Regression, are applied to identify patterns associated with the disease. The methodology involves data preprocessing, exploratory data analysis, model training, and performance evaluation using metrics such as accuracy, precision, and recall. The expected outcome is a model capable of supporting early diagnosis and decision-making in healthcare contexts. Additionally, the project discusses ethical considerations related to the use of artificial intelligence in medical applications, emphasizing data privacy and responsible use of predictive models.*

Resumo. *Este trabalho tem como objetivo desenvolver um modelo de Machine Learning para prever a ocorrência de diabetes com base em dados clínicos de pacientes. A proposta utiliza um dataset público contendo variáveis como glicose, IMC e idade, aplicando técnicas de classificação para identificar padrões relevantes. Espera-se que o modelo contribua como ferramenta de apoio à tomada de decisão na área da saúde.*

1. Introdução

A diabetes é uma doença crônica que afeta milhões de pessoas em todo o mundo, tornando o diagnóstico precoce essencial para o controle e a melhoria da qualidade de vida dos pacientes. Nesse contexto, o avanço da Inteligência Artificial, especialmente por meio de técnicas de Machine Learning, tem possibilitado a análise de grandes volumes de dados clínicos, auxiliando na identificação de padrões que podem contribuir para diagnósticos mais rápidos e precisos. Dessa forma, este projeto tem como objetivo desenvolver um modelo de Machine Learning capaz de prever a presença de diabetes a partir de características clínicas dos pacientes, como glicose, índice de massa corporal e idade. Para isso, será utilizado um dataset público amplamente reconhecido, aplicando algoritmos de classificação e analisando seu desempenho por meio de métricas apropriadas. A proposta busca demonstrar como técnicas relativamente simples de

aprendizado de máquina podem ser aplicadas em problemas reais da área da saúde, contribuindo como ferramenta de apoio à tomada de decisão.

2. Fundamentação Teórica

Machine Learning é uma área da Inteligência Artificial que permite que sistemas aprendam padrões a partir de dados.
Classificação é uma técnica utilizada para prever categorias, como presença ou ausência de uma doença.
Algoritmos como KNN e Regressão Logística são amplamente utilizados em problemas de classificação.

Diversos estudos utilizam Machine Learning para predição de doenças, obtendo bons resultados com algoritmos simples.

Modelos como Random Forest e Logistic Regression têm sido eficazes na identificação de padrões em dados médicos.

3. Metodologia e Resultados Esperados

O projeto seguirá as etapas de coleta de dados, pré-processamento, treinamento de modelos e avaliação de desempenho.
Serão utilizados algoritmos como KNN e Regressão Logística.

Será utilizado o dataset "Pima Indians Diabetes", disponível publicamente.
Ele contém informações como glicose, pressão arterial, IMC e idade.

A análise exploratória incluirá:

- Verificação de valores ausentes
- Estatísticas descritivas
- Visualização de dados

A preparação envolverá:

- Limpeza dos dados
- Normalização (se necessário)

Resultados esperados:
Espera-se obter um modelo capaz de classificar corretamente pacientes com e sem diabetes com boa precisão.

4. Resultados Parciais

O uso de IA na saúde deve considerar privacidade dos dados e evitar decisões automatizadas sem supervisão humana.

Até o momento, foram realizados estudos iniciais do dataset e compreensão das variáveis.

https://github.com/CampoCiroBig/Projeto-IA

References

BISHOP, Christopher M. *Pattern Recognition and Machine Learning*. New York: Springer, 2006.

ESTEVA, Andre et al. A guide to deep learning in healthcare. *Nature Medicine*, v. 25, p. 24–29, 2019.

GÉRON, Aurélien. *Hands-On Machine Learning with Scikit-Learn, Keras and TensorFlow*. Sebastopol: O'Reilly Media, 2019.

KAGGLE. Pima Indians Diabetes Database. Disponível em: https://www.kaggle.com/datasets/uciml/pima-indians-diabetes-database. Acesso em: 01 abr. 2026.